
Génération Augmentée par Récupération sur les Professions de Foi Électorales Françaises : Une Étude sur le Corpus Archelec

Ryan Samama
ryan.samama@ensae.fr

Abstract

Dans ce rapport, nous étudions l’impact de différents choix de composant d’un pipeline de Génération Augmentée par Récupération (RAG) sur un corpus de professions de foi des élections législatives françaises des années 1967 et 1981, issu de la collection Archelec. Ce corpus pose deux difficultés cumulées : un texte de qualité OCR variable issu de scans des années 1960–80, et un vocabulaire politique spécialisé peu représenté dans les modèles multilingues standards. Nous construisons un pipeline RAG complet et évaluons sept configurations selon quatre axes : récupération, taille des chunks, modèle d’embedding et modèle de génération sur un benchmark de 60 questions distinguant requêtes *nominatives* (portant sur un candidat précis) et *thématiques* (portant sur un sujet politique transversal). La récupération creuse (BM25) atteint un Hit Rate@10 de 0,617, devançant largement la récupération dense (0,367). La fusion hybride RRF (0,567) combine les avantages des deux approches. L’écart se creuse sur les requêtes nominatives (BM25 : 0,900 contre 0,500 pour la récupération dense), où la correspondance lexicale exacte des noms de candidats s’avère décisive. La taille des segments et le modèle d’encodage ont un effet plus modeste, tandis que le modèle de génération influe principalement sur la pertinence des réponses plutôt que sur leur fidélité. Nous appliquons enfin la meilleure configuration à trois études analytiques sur le corpus : évolution thématique entre 1967 et 1981, comparaison gauche/droite, et profil discursif des candidates femmes.

1 Introduction

Depuis la Ve République, les élections législatives françaises produisent des milliers de *professions de foi*, des tracts d’une à deux pages dans lesquels chaque candidat présente son programme aux électeurs avant le premier tour. Le projet Archelec (Sciences Po) a numérisé et catalogué une grande partie de ces documents, des élections de 1967 à celles de 1993, en les rendant accessibles sur Internet Archive avec des métadonnées structurées. Cette collection constitue une ressource NLP atypique : des documents courts, un vocabulaire politique d’époque, une qualité OCR hétérogène, et des métadonnées riches au niveau du candidat (nom, parti, département, sexe, profession).

Interroger ce corpus en langage naturel présente un intérêt réel pour les chercheurs en science politique (par exemple : « *Quelles propositions les candidats communistes bretons faisaient-ils sur le logement en 1967 ?* »), mais soulève des difficultés techniques. La recherche par mots-clés rate les paraphrases ; un système RAG Lewis et al. [2020] peut récupérer des passages pertinents et générer des réponses factuellement ancrées, mais le choix optimal de la stratégie de récupération sur du texte historique bruité reste ouvert.

Définition du problème : Étant donné une requête en langage naturel q portant sur l’histoire électorale française, on cherche à produire une réponse factuellement ancrée en récupérant les

passages les plus pertinents du corpus Archelec et en générant une réponse conditionnée sur ces passages. Deux sous-tâches sont distinguées : (i) **la récupération** : retourner les k segments les plus pertinents pour q ; (ii) **la génération** : produire une réponse concise et fidèle en français, conditionnée sur ces segments. Nous étudions deux régimes de requêtes correspondant à des besoins analytiques distincts : les requêtes *nominatives* (recherche d’un candidat précis) et les requêtes *thématiques* (synthèse transversale sur un thème politique).

Contributions :

- Nous constituons un corpus de 373 documents Archelec en veillant à bien représenter chaque département et chaque parti (§3), et en proposons une analyse descriptive politique, démographique et textuelle.
- Nous construisons un pipeline RAG couvrant l’ingestion OCR, trois stratégies de récupération et la génération par LLM, en justifiant pourquoi chaque choix a été fait. (§4).
- Nous conduisons une étude sur sept configurations et un benchmark de 60 questions (§5–6), identifiant BM25 et RRF hybride comme les meilleurs récupérateurs sur ce corpus.
- Nous appliquons la meilleure configuration à trois études analytiques du discours électoral (§7).

2 État de l’art

Génération augmentée par récupération : La RAG a été formalisée par Lewis et al. [2020], qui associent un récupérateur dense (DPR) à un générateur seq2seq (BART). Guu et al. [2020] pré-entraînent le récupérateur conjointement avec un modèle de langue. Izacard & Grave [2021] montrent que la fusion de plusieurs passages récupérés (Fusion-in-Decoder) améliore significativement la qualité des réponses. Self-RAG Asai et al. [2024] introduit des décisions de récupération adaptatives à l’inférence.

Récupération sparse et dense : BM25 Robertson & Zaragoza [2009] reste une baseline compétitive dans de nombreuses tâches de récupération Thakur et al. [2021]. Les modèles de récupération dense tels que DPR Karpukhin et al. [2020] et E5 Wang et al. [2022] surpassent BM25 sur des corpus propres et dans le domaine, mais peuvent être moins performants hors domaine ou sur du texte bruité Thakur et al. [2021]. Les approches hybrides combinant signaux sparses et denses via la Fusion par Rang Réciproque (RRF) Cormack et al. [2009] améliorent régulièrement les deux approches prises séparément, ce qui motive notre configuration hybride.

Évaluation des systèmes RAG : Les benchmarks RAG standards portent principalement sur Wikipedia en anglais Lewis et al. [2020], Karpukhin et al. [2020]. RAGAS Es et al. [2023] propose des métriques LLM-as-judge pour la fidélité et la pertinence des réponses, évitant ainsi l’annotation humaine. Chen et al. [2024] montrent que la qualité de la récupération est le facteur dominant dans la performance RAG de bout en bout, résultat cohérent avec nos conclusions.

NLP français et historique : Des modèles multilingues comme mBERT Devlin et al. [2019] et XLM-R Conneau et al. [2020] se transfèrent correctement au français, mais les registres historiques posent des difficultés supplémentaires. Gabay et al. [2022] documentent une dégradation OCR systématique sur des imprimés français du XIX^e siècle ; les scans Archelec des années 1960–80 présentent un profil similaire. Martin et al. [2020] montrent que des encodeurs français adaptés au domaine surpassent les modèles multilingues génériques sur des tâches françaises spécialisées, ce qui suggère un potentiel d’amélioration par fine-tuning que nous laissons à des travaux futurs.

3 Données

3.1 Le corpus Archelec

Le corpus Archelec regroupe des professions de foi des élections législatives françaises, hébergées sur Internet Archive sous la collection `archiveselectoralesducevipof`. Chaque item correspond à un scan numérisé de la profession de foi d’un candidat (généralement une à deux pages A4), accompagné de métadonnées structurées : nom du candidat, parti (*soutien*), département, numéro de circonscription, sexe et profession déclarée.

Nous nous concentrons sur deux élections : les **législatives de 1967** (tenues sous de Gaulle, premier tour le 5 mars) et les **législatives de 1981** (vague Mitterrand, premier tour le 14 juin). Ces deux scrutins encadrent une période charnière du réalignement politique français : les élections de 1967 mettent face à face la majorité gaulliste et une opposition structurée autour de la FGDS (fédération socialiste pré-PS) et du PCF, tandis que celles de 1981 consacrent un PS unifié face à une droite divisée entre RPR et UDF.

3.2 Constitution du corpus et répartition équilibrée

Internet Archive retourne les identifiants par ordre alphabétique, ce qui produirait un échantillon géographiquement biaisé (les départements *Ain*, *Aisne*, *Allier*... dominant). Nous appliquons une stratégie d'échantillonnage en deux étapes :

1. **Entrelacement par département** : Les identifiants sont regroupés par le code de département à trois chiffres inscrit dans chaque identifiant d'archive (ex. : 002 dans EL134_L_1981_06_002_05_1). Au sein de chaque groupe, les identifiants sont mélangés aléatoirement ; les groupes sont ensuite fusionnés par entrelacement *round-robin* afin que chaque département contribue équitablement à la liste ordonnée des candidats.
2. **Plafond souple par parti** : Pendant l'ingestion, toute formation politique qui dépasse 40% des documents déjà ingérés est temporairement ignorée, pour éviter que le PCF (parti le plus dominant) n'écrase les autres partis.

En ciblant 200 documents par année et après élimination des pages comportant moins de 50 caractères OCR, le corpus final compte **373 documents** (185 de 1967, 188 de 1981), soit **5 116 chunks**.

3.3 Analyse descriptive du corpus

Distribution politique. La figure 1 présente la distribution des partis après normalisation des labels. Le corpus de 1967 est dominé par le PCF et la FGDS ; celui de 1981 reflète le système partisan post-1971, avec le PCF et le PS à gauche et le RPR/UDF à droite. 27% des documents ne portent pas de label partisan récupérable (*N/R*), correspondant à des listes locales mineures ou à des métadonnées incomplètes.




FIGURE 1 – Distribution des principaux partis dans le corpus (après normalisation). La FGDS est spécifique à 1967 ; RPR et UDF à 1981.

Distribution géographique. La figure 2 montre les départements les plus représentés. L'entrelacement *round-robin* plafonne chaque département à environ cinq documents, assurant une couverture géographique beaucoup plus uniforme que le tri alphabétique. L'échantillon 1981 seul couvre 104 départements distincts.

Genre. Le corpus compte 352 candidats hommes (94,4%) et 21 femmes (5,6%) — voir figure 3. Ce déséquilibre reflète la réalité historique des législatives françaises de cette période : les femmes représentaient une infime minorité des candidats, en particulier en 1967, six ans avant la première loi française encourageant la candidature politique féminine.




FIGURE 2 – Top 15 des départements par nombre de documents. La plupart des départements contribuent 3 à 5 documents.





FIGURE 3 – Distribution du genre des candidats. La quasi-absence de femmes reflète la réalité historique des législatives de 1967–1981.

Longueur des documents et chunks La figure 4 présente la distribution des longueurs des chunks et le nombre de chunks par document. Les chunks font en moyenne 373 caractères (médiane : 401) et chaque document produit en moyenne 13,7 chunks. La distribution montre une concentration entre 300 et 500 caractères, avec une queue de chunks courts (en-têtes, signatures) et une queue plus étroite de chunks longs (programmes denses).



(a) Distribution des longueurs de chunks (caractères).

(b) Nombre de chunks par document.

FIGURE 4 – Statistiques des chunks pour les 373 documents du corpus.

4 Pipeline RAG

4.1 Choix de modèles et justification

Stratégie de segmentation. Les professions de foi sont courtes mais hétérogènes : un même document peut contenir un titre, une notice biographique, plusieurs paragraphes sur un programme et un appel au vote. Une segmentation à taille fixe couperait ces unités naturelles. Nous utilisons donc un **découpeur récursif** qui essaie successivement des délimiteurs de granularité décroissante (saut de paragraphe → fin de phrase → ponctuation → espace), en ciblant 512 caractères. Cette taille équilibre la spécificité de la récupération (un segment doit couvrir une affirmation cohérente) et la richesse contextuelle (assez de texte pour un encodage significatif). Nous la comparons à des segmentations fixes de 256 et 1024 caractères dans notre étude.

Modèle d’encodage. Nous utilisons `intfloat/multilingual-e5-small` Wang et al. [2022] comme encodeur de référence. Il couvre le français nativement, est léger (384 dimensions, 118M paramètres), et a été entraîné à comparer des textes entre eux, avec peu de supervision, sur des données web en plusieurs langues, dont du contenu politique français. Nous le comparons à `multilingual-e5-large` (1024 dimensions, 560M paramètres) pour évaluer si un encodeur plus grand améliore la récupération dans ce domaine.

Stratégie de récupération. Nous incluons trois récupérateurs. La récupération dense avec E5 est la baseline naturelle pour la similarité sémantique. BM25 étant donné les caractéristiques du corpus : le bruit OCR et les noms propres (noms de candidats, de départements, sigles de partis) sont gérés plus robustement par la correspondance exacte de termes que par les encodages d’un modèle entraîné sur du texte propre. La fusion hybride RRF combine les deux signaux sans avoir besoin de modèle de fusion entraîné, ce qui en fait une combinaison idéal sans paramètres.

Modèle de génération. Nous utilisons `gpt-4.1-nano` par défaut : rapide, économique, et suffisant pour la génération ancrée de forme courte. Nous le comparons à `gpt-4o-mini` pour évaluer l’impact de la capacité du modèle sur la qualité des réponses, à récupération constante.

4.2 Ingestion

Pour chaque document, nous récupérons la transcription OCR au format DjVuTXT depuis Internet Archive et les métadonnées structurées via l’API Archive.org. Le texte est découpé avec le découpeur récursif décrit ci-dessus. Les segments de moins de 48 caractères sont éliminés. Les encodages sont calculés avec `multilingual-e5-small` (384 dimensions) et stockés dans une base de données vectorielle Qdrant avec similarité cosinus.

4.3 Récupération

Nous implémentons trois stratégies de récupération évaluées à $k = 10$:

Dense. La requête est encodée avec le même encodeur utilisé à l’ingestion. La recherche par voisin le plus proche dans Qdrant retourne les k segments avec la similarité cosinus la plus élevée, filtrés avec un treshold de 0,4.

BM25. Nous construisons un index BM25Okapi Robertson & Zaragoza [2009] en mémoire sur l’ensemble des segments. La tokenisation applique une mise en minuscules et une suppression de la ponctuation. Les segments avec un score BM25 nul sont éliminés.

RRF hybride. Nous fusionnons les classements dense et BM25 par Fusion par Rang Réciproque Cormack et al. [2009] :

$$s_{RRF}(d) = \sum_{r \in \{dense, BM25\}} \frac{1}{k_0 + rang_r(d)}, \quad k_0 = 60.$$

Chaque sous-récupérateur extrait $2k$ candidats ; les k meilleurs segments fusionnés sont retournés. La pondération n’a pas été étudié ici.

4.4 Génération

Les k segments récupérés sont concaténés et transmis comme contexte à un LLM OpenAI. Le prompt système demande au modèle de répondre en français, strictement ancré dans le contexte fourni, en citant des candidats ou des années spécifiques si pertinent, et d’indiquer explicitement lorsque le contexte est insuffisant.

5 Évaluation

5.1 Construction du benchmark

Nous générons un benchmark de 60 paires question-réponse (QA) avec GPT-4.1-nano, en tirant 15 documents par année électorale et en sélectionnant le chunk le plus long pour chaque document. Chaque chunk produit deux questions :

- **Nominative** : la question nomme explicitement le candidat, l’année et le département (ex. : « *Quelles mesures économiques proposait le candidat [nom], PCF dans le [département], lors des législatives de 1981 ?* »). Ces questions évaluent la capacité du pipeline à récupérer un document précis connu.
- **Thématique** : la question porte sur un thème politique sans nommer aucun candidat ni profession de foi (ex. : « *Quelle position les candidats de 1967 prenaient-ils sur la politique agricole ?* »). Ces questions évaluent la récupération sémantique transversale.

Le benchmark final contient 60 questions (30 nominatives, 30 thématiques). Chaque question enregistre le `source_doc_id` du segment source, permettant un jugement de pertinence au niveau du document.

5.2 Métriques

Récupération. Les identifiants des segments récupérés sont projetés vers leur document parent en supprimant le suffixe de segment (`_PF_XX`).

- **Hit Rate@ k** : fraction des questions pour lesquelles le document source apparaît parmi les k segments récupérés.
- **MRR@ k** : Rang Réciproque Moyen du premier segment pertinent.
- **Précision@ k** : fraction des k segments récupérés appartenant au document source.

Génération. Un juge LLM (GPT-4.1-nano) note sur $[0, 1]$:

- **Fidélité** : chaque affirmation factuelle de la réponse est-elle soutenue par le contexte récupéré ?
- **Pertinence de la réponse** : la réponse adresse-t-elle directement la question posée ?

5.3 Configurations d’ablation

Le tableau 1 résume les sept configurations. Chacune fait varier une dimension en maintenant les autres à leur valeur de référence (baseline).

TABLE 1 – Configurations de l’étude d’ablation. La baseline est en gras.

Nom	Récupération	Segmentation	Encodage	Génération
Baseline	Dense	Récuratif 512	E5-Small (384d)	GPT-4.1-nano
BM25	BM25	Récuratif 512	E5-Small	GPT-4.1-nano
Hybride	RRF	Récuratif 512	E5-Small	GPT-4.1-nano
Fixe-256	Dense	Fixe 256	E5-Small	GPT-4.1-nano
Fixe-1024	Dense	Fixe 1024	E5-Small	GPT-4.1-nano
E5-Large	Dense	Récuratif 512	E5-Large (1024d)	GPT-4.1-nano
GPT-4o-mini	Dense	Récuratif 512	E5-Small	GPT-4o-mini

6 Résultats

6.1 Résultats principaux

Le tableau 2 reporte les cinq métriques pour les sept configurations à $k = 10$.

TABLE 2 – Résultats d’évaluation ($k = 10$). En gras : meilleure valeur par colonne.

Configuration	Hit Rate	MRR	Précision	Fidélité	Pertinence
Baseline	0,367	0,185	0,045	0,332	0,378
BM25	0,617	0,387	0,077	0,411	0,453
Hybride (RRF)	0,567	0,359	0,057	0,413	0,478
Fixe-256	0,333	0,198	0,048	0,332	0,356
Fixe-1024	0,333	0,156	0,047	0,337	0,469
E5-Large	0,317	0,181	0,047	0,420	0,512
GPT-4o-mini	0,367	0,185	0,045	0,319	0,420

La figure 5 présente les mêmes résultats pour chaque stratégie, avec des lignes pointillées marquant la performance de la baseline.




FIGURE 5 – Étude des configurations selon quatre dimensions du pipeline. Chaque sous-figure fait varier un composant

6.2 Requêtes nominatives vs thématiques

Le tableau 3 reporte le Hit Rate séparément pour les deux types de questions. La figure 6 présente la même décomposition sur l’ensemble des groupes.

7 Application : Analyse du corpus avec la meilleure configuration

Ayant identifié la fusion RRF hybride comme la configuration la plus robuste sur les deux types de requêtes, nous l’utilisons pour conduire trois études analytiques sur le corpus Archelec. Pour chaque

TABLE 3 – Hit Rate@10 par type de question.

Configuration	Nominative ($n = 30$)	Thématique ($n = 30$)
Baseline	0,500	0,233
BM25	0,900	0,333
Hybride (RRF)	0,800	0,333
Fixe-256	0,500	0,167
Fixe-1024	0,500	0,167
E5-Large	0,467	0,167
GPT-4o-mini	0,500	0,233




FIGURE 6 – Hit Rate par type de question sur l’ensemble des groupes d’ablation.

étude, nous sélectionnons aléatoirement jusqu’à 25 segments pertinents depuis Qdrant (filtrés par année, parti ou sexe) et demandons à GPT-4.1-nano une analyse structurée ancrée dans les textes récupérés.

7.1 Étude 1 : Évolution thématique 1967–1981

Nous interrogeons le système sur trois thèmes — politique économique et emploi, politique sociale, propositions institutionnelles — séparément pour 1967 et 1981.

Économie et emploi : En 1967, le discours économique est fortement agricole : des candidats de tout bord invoquent la défense des exploitations familiales, la parité des prix agricoles et l’emploi rural. Une profession de foi PCF en Creuse réclame « une aide spéciale et prioritaire aux exploitations familiales » ; un candidat FGDS en Aveyron plaide pour « la réforme de la distribution » pour améliorer les revenus des agriculteurs. La question industrielle apparaît surtout à travers la stagnation des salaires : un manifeste note qu’en dépit d’une croissance de 60% du revenu national, le pouvoir d’achat n’a pas suivi. En 1981, le centre de gravité économique s’est déplacé vers la politique industrielle urbaine. Le chômage est le thème dominant — nommé explicitement, avec des appels à la réindustrialisation, à la réduction du temps de travail et à la nationalisation de secteurs stratégiques. Les professions de foi de 1981 reflètent le programme de l’Union de la Gauche et, côté droit, un discours centré sur « la rigueur », la compétitivité fiscale et la résistance aux nationalisations.

Politique sociale : Les deux élections comportent un discours fort sur l’éducation, la santé et le logement, mais le cadrage change. En 1967, l’accent est mis sur la construction d’infrastructures (établissements scolaires en zone rurale, accès aux soins hors des villes). En 1981, le discours est davantage fondé sur les droits : l’accès au logement, à la garde d’enfants et à l’éducation est présenté comme un droit plutôt que comme un service à fournir. Ce glissement reflète l’évolution plus large de la rhétorique de la gauche française après 1968, du planisme étatique vers les droits sociaux.

Propositions institutionnelles : En 1967, peu de candidats proposent des réformes institutionnelles explicites ; le cadre dominant oppose le programme de la majorité gaulliste à celui de l’opposition. En 1981, la dimension institutionnelle est plus présente : les candidats de gauche invoquent le «

changement » promis par la campagne présidentielle de Mitterrand, tandis que ceux de droite mettent en garde contre l'instabilité institutionnelle en cas de victoire de la gauche.

7.2 Étude 2 : Discours de gauche et de droite

Nous comparons 25 chunks échantillonnés aléatoirement parmi les partis de gauche (PCF, PS, FGDS, PSU, LO, MRG; $n = 1\,137$ segments au total) et 25 parmi les partis de droite (RPR, UDF, CD, RI; $n = 347$ segments).

Thèmes prioritaires : Les candidats de gauche mettent au premier plan la redistribution, la lutte des classes et les droits des travailleurs. La FGDS (1967) propose « un impôt sur le capital visant à taxer l'augmentation de la fortune spéculative » tout en exonérant les petits salariés. Le PCF structure systématiquement son propos autour des « travailleurs » et de la « classe ouvrière ». Les candidats de droite privilégient la liberté individuelle, la souveraineté nationale et la stabilité institutionnelle. Un manifeste libéral de 1967 plaide pour « le développement économique LIBREMENT du régional au national » ; un manifeste RPR de 1981 prévient explicitement contre « le collectivisme et l'étatisation ».

Valeurs et références : La gauche mobilise des références historiques à la Résistance, au Front populaire et à la solidarité de classe. La droite s'appuie sur le gaullisme, l'ordre républicain et la menace du socialisme à la soviétique. Cette distinction est remarquablement stable entre les deux élections étudiées.

Style rhétorique : Les professions de foi de gauche tendent à utiliser une rhétorique confrontationnelle (nommer les adversaires, citer des chiffres de chômage, évoquer les luttes ouvrières), tandis que celles de droite font davantage appel à la continuité et à la compétence. Les deux camps s'adressent aux électeurs à la deuxième personne (« Vous ») et usent de promesses conditionnelles (« Si vous m'élisez »), mais la gauche adopte plus souvent un cadrage adversarial qui nomme des mécanismes économiques spécifiques à réformer.

7.3 Étude 3 : Profil discursif des candidates femmes

Sur les 373 documents du corpus, 21 (5,6%) sont produits par des candidates femmes. Un résultat notable de l'exploration du corpus est que **toutes les 21 candidates appartiennent à des partis de gauche** : PCF (5), LO (5), PSU (4), PS (4), FGDS (1), MRG (1), avec une non identifiée. Aucune candidate ne provient de partis de droite (RPR, UDF, CD, RI). Ce fait reflète la réalité historique de la participation politique française et constitue en lui-même un résultat sur la composition de la collection Archelec.

Thèmes spécifiques aux femmes : Les candidates, notamment celles du PSU, sont les seules du corpus à aborder explicitement les droits des femmes comme enjeu politique. Une candidate PSU en Seine-Maritime (1981) revendique « le droit à l'avortement libre et gratuit pour toutes les femmes de toutes les nationalités, y compris les mineures » et propose « la diminution du temps de travail » comme mécanisme de partage des tâches domestiques. Une candidate PSU dans les Hautes-Pyrénées appelle à reconnaître « les Droits des Femmes » en parallèle de propositions de réforme démocratique. Les candidates PS mettent davantage en avant leurs titres professionnels (mandats électifs, fonctions administratives) sans référence explicite au genre.

Comparaison avec les candidats hommes de gauche : Par rapport à un échantillon apparié de candidats hommes des mêmes partis, les candidates présentent un profil thématique distinct : elles combinent plus fréquemment la transformation sociale (anticapitalisme, réforme institutionnelle) avec des revendications explicitement féministes. Les candidats masculins des mêmes formations se concentrent presque exclusivement sur la politique économique et la lutte des classes, sans référence à l'égalité de genre. Cela suggère que la candidature féminine en France de 1967–1981 ne se réduisait pas à une projection de l'idéologie gauchiste générale, mais comportait une couche féministe supplémentaire que les candidats masculins ne portaient pas.

8 Discussion

Pourquoi BM25 domine sur ce corpus : La supériorité de BM25 sur la récupération dense s'explique de plusieurs façon. Les requêtes nominatives contiennent des noms propres (candidats, départements, années) qui apparaissent textuellement dans le document source : *Lemret, Aisne, 1981*. BM25 exploite directement ces "ancres" précises. La récupération dense doit combler l'écart entre la formulation de la requête et la représentation encodée du texte OCR, un écart plus large pour deux raisons. D'abord, les erreurs OCR corrompent les formes des mots de manière imprévisible (« *lcs* » pour « *les* », « *rn* » pour « *m* »), ce qui déplace le vecteur du chunk loin de celui de la requête même quand le contenu sous-jacent correspond. Ensuite, le vocabulaire politique français de 1967–1981 (« *suppléant* », « *FGDS* », « *autogestion* ») peut être rare ou absent des données d'entraînement d'E5, entraîné principalement sur du texte web moderne.

Le Hit Rate nominatif de 0,900 pour BM25 (quasi parfait) montre que pour les requêtes de consultation factuelle sont entièrement résolu par un index creux simple. Les 10% d'échecs restants correspondent vraisemblablement à des documents où le nom du candidat est fortement corrompu par l'OCR.

Pourquoi l'hybride dépasse le dense mais pas BM25 : La fusion RRF (Hit Rate 0,567) améliore substantiellement le dense (0,367) mais n'atteint pas BM25 (0,617). Ce résultat est cohérent avec la littérature Thakur et al. [2021] : quand un signal est beaucoup plus fort que l'autre, la fusion tend à diluer le signal dominant. Sur les requêtes thématiques (0,333 pour BM25 et hybride), les deux méthodes sont identiques, ce qui signifie que les gains de l'hybride viennent entièrement des requêtes nominatives où BM25 domine. Ajuster le poids α de la RRF en faveur de BM25 pourrait améliorer ce résultat, mais nous n'avons pas exploré cela ici.

Segmentation : les frontières comptent plus que la taille : Ni le découpage fixe-256 ni le fixe-1024 ne bat la baseline réursive-512 (0,367 contre 0,333 pour les deux). La segmentation fixe coupe à des positions arbitraires dans les caractères, fréquemment au milieu d'une phrase. Une phrase qui contient le nom du candidat et sa proposition peut être répartie sur deux segments, aucun des deux n'étant individuellement assez fort pour bien se classer. Le découpeur réursif, en respectant les frontières de phrases, maintient ces unités intactes. La fixe-1024 produit le MRR le plus faible (0,156), suggérant que même lorsque le bon document est récupéré, son contenu est noyé dans un segment plus long dont l'encodage est dilué par le contexte environnant.

Modèle d'encodage : plus grand n'est pas toujours meilleur pour la récupération : E5-Large (1024d) sous-performe légèrement E5-Small (384d) en Hit Rate (0,317 contre 0,367). Une explication est que le modèle plus grand, entraîné avec un objectif contrastif plus difficile, pousse les représentations plus loin les unes des autres dans l'espace d'encodage ; combiné au bruit OCR, cela peut entraîner un filtrage plus sévère par seuil de score. En revanche, E5-Large obtient la meilleure Pertinence de réponse de toutes les configurations (0,512), ce qui suggère que ses représentations plus riches profitent à la génération même sans changer les documents récupérés.

Modèle de génération : arbitrage fidélité/pertinence : GPT-4o-mini et GPT-4.1-nano récupèrent de façon identique. GPT-4o-mini produit des réponses avec une pertinence perçue plus élevée (0,420 contre 0,378) mais une fidélité moindre (0,319 contre 0,332). Cela reflète une tendance connue des modèles plus grands à « sur-générer » : ils comblent les lacunes du contexte avec des informations plausibles mais non soutenues, augmentant la fluidité au détriment de l'ancrage factuel. Pour un usage RAG où la précision factuelle prime, le modèle plus petit est préférable.

Les requêtes thématiques restent un problème ouvert : Le meilleur Hit Rate thématique toutes configurations confondues est 0,333, ce qui signifie que deux tiers des requêtes thématiques échouent à récupérer le document source dans le top 10. Une requête thématique comme « *positions des candidats sur les salaires en 1967* » ne contient aucun mot-clé spécifique à un document, et le document pertinent peut ne pas employer exactement les mêmes termes. Résoudre ce problème nécessiterait une expansion de requête, un re-classement par encodeur croisé entraîné sur du texte politique français, ou un corpus plus large où davantage de documents sont pertinents pour un thème donné.

Limites : Notre benchmark est généré automatiquement, ce qui introduit un risque de circularité : GPT-4.1-nano génère les questions et évalue les réponses. Une validation manuelle d’un sous-ensemble renforcerait l’évaluation. Par ailleurs, notre corpus ne couvre que deux années électorales ; le système partisan de 1967 (FGDS, CD) diffère substantiellement de celui de 1981 (PS, RPR, UDF), et les résultats peuvent ne pas se généraliser à d’autres années. Enfin, la Précision@10 est faible pour toutes les configurations (0,045–0,077), reflétant le fait que chaque document contribue peu de segments relativement à la taille de la collection.

9 Conclusion

Nous avons évalué sept configurations de pipeline RAG sur un corpus de professions de foi électorales françaises historiques. La principale conclusion est que la stratégie de récupération est la variable de conception dominante : BM25 atteint un Hit Rate de 0,617, loin devant E5-Small dense (0,367), et la fusion hybride RRF (0,567) offre une combinaison robuste des deux. Cette hiérarchie reflète les caractéristiques spécifiques du corpus (des documents courts avec bruit OCR et des noms propres comme principaux discriminants) plutôt qu’une propriété générale des systèmes RAG.

La qualité des chunks importe plus que leur taille : le chunking récursif respectueux des phrases surpasse les alternatives à taille fixe. La taille du modèle d’encodage a un effet inverse surprenant sur la récupération mais améliore la pertinence de la génération. Le modèle de génération introduit un arbitrage fidélité/fluidité, avec le modèle plus petit préférable pour la précision factuelle.

Les études applicatives révèlent des résultats substantiels : un glissement du discours agricole vers le discours industriel urbain entre 1967 et 1981, une opposition nette entre rhétorique redistributive à gauche et rhétorique libérale-nationale à droite, et un profil féministe distinct chez les candidates femmes (toutes de gauche) par rapport à leurs homologues masculins des mêmes formations.

Les pistes futures incluent l’extension du corpus aux années 1973, 1978, 1988 et 1993, le fine-tuning d’un encodeur sur du texte politique français pour améliorer la récupération thématique, et l’exploration des filtres de métadonnées (parti, département) comme contraintes de récupération pour les requêtes analytiques.

Références

- Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil et Hannaneh Hajishirzi. Self-RAG : Learning to retrieve, generate, and critique through self-reflection. *ICLR*, 2024.
- Jiawei Chen, Hongyu Lin, Xianpei Han et Le Sun. Benchmarking large language models in retrieval-augmented generation. *AAAI*, 2024.
- Alexis Conneau, Kartikay Khandelwal, Naman Goyal et al. Unsupervised cross-lingual representation learning at scale. *ACL*, 2020.
- Gordon V. Cormack, Charles L.A. Clarke et Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. *SIGIR*, 2009.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee et Kristina Toutanova. BERT : Pre-training of deep bidirectional transformers for language understanding. *NAACL*, 2019.
- Shahul Es, Jithin James, Luis Espinosa-Anke et Steven Schockaert. RAGAS : Automated evaluation of retrieval augmented generation. *EACL (Findings)*, 2024.
- Simon Gabay, Thibault Clérice et Christian Reul. OCR and post-correction of historical French documents. *Journal of Data Mining & Digital Humanities*, 2022.
- Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat et Ming-Wei Chang. REALM : Retrieval-augmented language model pre-training. *ICML*, 2020.
- Gautier Izacard et Édouard Grave. Leveraging passage retrieval with generative models for open domain question answering. *EACL*, 2021.
- Vladimir Karpukhin, Barlas Oguz, Sewon Min et al. Dense passage retrieval for open-domain question answering. *EMNLP*, 2020.

- Patrick Lewis, Ethan Perez, Aleksandra Piktus et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. *NeurIPS*, 2020.
- Louis Martin, Benjamin Muller, Pedro Javier Ortiz Suárez et al. CamemBERT : a Tasty French Language Model. *ACL*, 2020.
- Stephen Robertson et Hugo Zaragoza. The probabilistic relevance framework : BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4) :333–389, 2009.
- Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava et Iryna Gurevych. BEIR : A heterogeneous benchmark for zero-shot evaluation of information retrieval models. *NeurIPS Datasets and Benchmarks*, 2021.
- Liang Wang, Nan Yang, Xiaolong Huang et al. Text embeddings by weakly-supervised contrastive pre-training. *arXiv :2212.03533*, 2022.